

Seminarski rad

Kolegij: Računalni vid

Tema: Detekcija objekata pomoću YOLOv8 modela

Student: Katarina Galić Smjer: Podatkovna znanost i inženjerstvo

Mentor: Red. prof. dr. sc. Irena Galić

Mostar, veljača 2026.

SAŽETAK

Razvoj računalnog vida omogućio je računalnim sustavima da analiziraju i interpretiraju vizualne informacije sa slika i videozapisa. Jedan od važnih zadataka u tom području je detekcija objekata, koja omogućuje prepoznavanje i lociranje različitih objekata unutar slike. Za razliku od klasične klasifikacije slika, gdje se određuje samo kojoj kategoriji slika pripada, kod detekcije objekata potrebno je odrediti i položaj objekta na slici pomoću pravokutnih okvira (engl. bounding box). U ovom radu prikazan je postupak detekcije objekata korištenjem modela YOLOv8 (You Only Look Once), jednog od suvremenih modela dubokog učenja namijenjenih detekciji objekata u stvarnom vremenu. Model je primijenjen na PASCAL VOC skupu podataka, koji sadrži velik broj označenih slika s različitim kategorijama objekata. Poseban naglasak stavljen je na pripremu podataka, treniranje modela te analizu dobivenih rezultata. Evaluacija modela provedena je korištenjem standardnih metrika poput precision, recall i F1-score, kao i matrice zabune. Također su prikazane vizualizacije detekcije objekata na testnim slikama pomoću bounding boxova. Dobiveni rezultati uspoređeni su s jednostavnijim detekcijskim modelom SSD kako bi se dobio bolji uvid u prednosti i ograničenja pojedinih pristupa. Cilj rada je prikazati mogućnosti primjene YOLOv8 modela u zadacima detekcije objekata te analizirati njegovu učinkovitost na odabranom skupu podataka.

SADRŽAJ

1	UVOD	1
2	RAČUNALNI VID I DETEKCIJA OBJEKATA.....	2
2.1	Razlika između klasifikacije i detekcije objekata.....	3
2.2	Primjene detekcije objekata.....	5
2.3	Metode za detekciju objekata	7
3	YOLO model za detekciju objekata	9
3.1	Osnovna ideja YOLO algoritma	9
3.2	Razvoj YOLO modela kroz verzije	11
3.3	YOLOv8 model i njegove karakteristike.....	12
4	Skup podataka PASCAL VOC i priprema podataka	14
4.1	Opis skupa podataka	14
4.2	Anotacije i struktura podataka	15
4.3	Priprema podataka za treniranje modela	16
5	Implementacija YOLOv8 modela	17
5.1	Postavljanje radnog okruženja.....	17
5.2	Treniranje modela	18
5.3	Evaluacija modela.....	18
6	Analiza rezultata i usporedba modela	19
6.1	Precision, recall i F1-score	19
6.2	Matrica zabune (Confusion Matrix)	20
6.3	Vizualizacija detekcije objekata	23
6.4	Usporedba s SSD modelom.....	25
7	Zaključak	28
8	Literatura	29
9	Popis slika	30

1 UVOD

Računalni vid predstavlja jedno od najbrže razvijajućih područja umjetne inteligencije. Njegov osnovni cilj je omogućiti računalima razumijevanje vizualnih informacija na način sličan ljudskoj percepciji. Zahvaljujući napretku u području dubokog učenja i povećanju dostupnosti velikih skupova podataka, računalni sustavi danas mogu uspješno prepoznavati objekte, analizirati scene te donositi zaključke na temelju vizualnih podataka.

Jedan od važnijih zadataka u računalnom vidu je detekcija objekata. Za razliku od jednostavne klasifikacije slika, gdje se određuje samo kojoj kategoriji slika pripada, kod detekcije objekata potrebno je identificirati više objekata na slici te odrediti njihovu točnu lokaciju. Takvi sustavi danas imaju široku primjenu u različitim područjima, primjerice u autonomnim vozilima, video nadzoru, medicinskoj dijagnostici i industrijskoj automatizaciji. U posljednjih nekoliko godina razvijen je niz modela temeljenih na dubokim neuronskim mrežama koji omogućuju učinkovitu detekciju objekata. Jedan od najpoznatijih pristupa je YOLO (You Only Look Once) arhitektura, koja omogućuje detekciju objekata u stvarnom vremenu analizirajući cijelu sliku u jednom prolazu kroz mrežu. Najnovija verzija ovog modela, YOLOv8, donosi dodatna poboljšanja u pogledu točnosti, brzine i jednostavnosti implementacije. U ovom radu prikazan je postupak implementacije YOLOv8 modela za detekciju objekata na slikama koristeći PASCAL VOC skup podataka. Opisani su koraci pripreme podataka, treniranja modela i evaluacije dobivenih rezultata. Također je provedena analiza performansi modela pomoću standardnih metrika te usporedba s jednostavnijim detekcijskim modelom kako bi se dobio bolji uvid u učinkovitost primijenjenog pristupa.

2 RAČUNALNI VID I DETEKCIJA OBJEKATA

Računalni vid predstavlja jedno od važnijih područja umjetne inteligencije koje se bavi razvojem metoda i algoritama koji omogućuju računalima analizu i razumijevanje vizualnih informacija. Osnovna ideja ovog područja jest omogućiti računalnim sustavima da iz slika ili videozapisa izdvoje korisne informacije te na temelju njih donesu određene zaključke. Drugim riječima, cilj računalnog vida je razviti sustave koji mogu interpretirati vizualne podatke na način sličan ljudskom načinu opažanja. Ljudi svakodnevno koriste vid kako bi prepoznali objekte, razumjeli okolinu i reagirali na promjene u prostoru. Računalni vid pokušava postići sličnu sposobnost kod računala koristeći matematičke modele, algoritme obrade slike i metode strojnog učenja. Iako se prvi pokušaji razvoja računalnog vida pojavljuju još sredinom prošlog stoljeća, značajniji napredak postignut je tek posljednjih desetak godina, prvenstveno zahvaljujući razvoju dubokih neuronskih mreža i povećanju računalne snage.

U početnim fazama razvoja računalnog vida naglasak je bio na korištenju ručno definiranih značajki slike, poput rubova, tekstura ili boja. Takvi pristupi zahtijevali su velik angažman stručnjaka koji su morali unaprijed odrediti koje su karakteristike slike važne za određeni zadatak. S razvojem dubokog učenja pristup se značajno promijenio. Umjesto ručnog definiranja značajki, neuronske mreže mogu same učiti relevantne obrasce iz velikih skupova podataka. Ovakav pristup omogućio je znatno bolje rezultate u mnogim zadacima računalnog vida. Jedan od najvažnijih zadataka u području računalnog vida je prepoznavanje objekata na slici. Taj proces uključuje identificiranje različitih elemenata unutar slike, poput ljudi, vozila, životinja ili drugih objekata. Ovisno o složenosti zadatka, sustav može samo prepoznati prisutnost određenog objekta ili dodatno odrediti njegov položaj na slici. Upravo iz tog razloga razvijene su različite metode koje omogućuju precizniju analizu vizualnog sadržaja. Detekcija objekata predstavlja napredniji zadatak u kojem model mora pronaći objekte na slici i označiti njihovu lokaciju. Za razliku od jednostavnijih metoda koje analiziraju cijelu sliku kao jednu cjelinu, kod detekcije objekata potrebno je identificirati svaki objekt zasebno. To znači da model mora biti sposoban razlikovati više objekata na istoj slici te odrediti njihovu kategoriju i položaj. U praksi se položaj objekta najčešće označava pravokutnim okvirom koji se naziva *bounding box*. Ovaj okvir definira

područje slike unutar kojeg se nalazi detektirani objekt. Uz lokaciju objekta model također dodjeljuje oznaku klase, odnosno kategoriju kojoj objekt pripada. Na primjer, model može detektirati osobu, automobil ili bicikl te oko svakog od tih objekata postaviti odgovarajući okvir. Razvoj učinkovitih modela za detekciju objekata postao je posebno važan s pojavom velikih skupova podataka koji sadrže ručno označene slike. Takvi skupovi omogućuju treniranje modela koji mogu učiti iz velikog broja primjera i postupno poboljšavati svoju točnost. Jedan od poznatijih skupova podataka koji se često koristi u istraživanjima računalnog vida je PASCAL VOC, koji sadrži slike s različitim kategorijama objekata i pripadajućim anotacijama. Suvremeni pristupi detekciji objekata uglavnom se temelje na dubokim neuronskim mrežama koje mogu istovremeno analizirati vizualne značajke slike i predviđati položaj objekata. Takvi modeli postižu visoku razinu točnosti i mogu raditi u gotovo stvarnom vremenu, što omogućuje njihovu primjenu u različitim sustavima i aplikacijama.

Zahvaljujući tim mogućnostima, detekcija objekata danas ima važnu ulogu u mnogim tehnološkim rješenjima. Sustavi temeljeni na računalnom vidu koriste se u autonomnim vozilima za prepoznavanje sudionika u prometu, u sigurnosnim sustavima za nadzor prostora, ali i u različitim industrijskim procesima gdje je potrebno automatski prepoznati određene objekte ili nepravilnosti. Razvoj ovih tehnologija i dalje je vrlo aktivno područje istraživanja, a novi modeli i algoritmi kontinuirano poboljšavaju brzinu i točnost detekcije. Upravo zbog toga detekcija objekata predstavlja jedan od ključnih problema suvremenog računalnog vida te ima značajan potencijal za primjenu u brojnim područjima.

2.1 Razlika između klasifikacije i detekcije objekata

U području računalnog vida postoji više različitih zadataka koji omogućuju računalnim sustavima analizu i razumijevanje vizualnog sadržaja. Među najvažnijim zadacima nalaze se klasifikacija slika i detekcija objekata. Iako oba pristupa imaju za cilj prepoznati sadržaj slike, između njih postoje značajne razlike u načinu na koji model obrađuje podatke i kakve rezultate daje. Klasifikacija slika smatra se jednim od osnovnih problema računalnog vida. Kod klasifikacije model analizira cijelu sliku kao jednu cjelinu te pokušava odrediti kojoj kategoriji slika pripada.

Drugim riječima, model dobiva sliku kao ulaz i kao rezultat daje oznaku klase koja najbolje opisuje sadržaj slike. Na primjer, ako je na slici prikazan automobil, model će sliku klasificirati kao „automobil“. Ovakav pristup vrlo je koristan kada je cilj prepoznati dominantni objekt ili temu slike, ali ne pruža detaljne informacije o položaju objekta unutar slike. Jedno od ograničenja klasifikacije slika je to što model ne može razlikovati više objekata koji se nalaze na istoj slici. Ako se na slici nalazi više različitih objekata, model će obično odrediti samo jednu klasu koja najviše odgovara sadržaju slike. Također, klasifikacija ne omogućuje određivanje točne lokacije objekta, odnosno ne daje informaciju o tome gdje se objekt nalazi u prostoru slike. Za razliku od klasifikacije, detekcija objekata predstavlja složeniji zadatak jer uključuje i prepoznavanje objekta i određivanje njegove lokacije. Model za detekciju objekata mora pronaći sve relevantne objekte na slici te za svaki objekt odrediti njegovu kategoriju i položaj. Položaj objekta obično se označava pravokutnim okvirom koji se naziva *bounding box*. Taj okvir definira područje slike u kojem se nalazi detektirani objekt. Kod detekcije objekata model može identificirati više objekata na jednoj slici, čak i ako pripadaju različitim kategorijama. Na primjer, na slici se mogu nalaziti osoba, bicikl i automobil, a model treba detektirati svaki od tih objekata i označiti ih odgovarajućim okvirima. Osim toga, model obično dodjeljuje i vrijednost pouzdanosti (*confidence score*) koja pokazuje kolika je vjerojatnost da detektirani objekt zaista pripada određenoj klasi.

Zbog ovih zahtjeva detekcija objekata predstavlja znatno kompleksniji problem u odnosu na klasifikaciju slika. Model mora istovremeno analizirati različite dijelove slike, pronaći potencijalne objekte i procijeniti njihovu klasifikaciju i lokaciju. Upravo zbog toga se u suvremenim sustavima koriste duboke neuronske mreže koje su sposobne naučiti složene obrasce iz velikog broja označenih podataka. Važno je naglasiti da su klasifikacija slika i detekcija objekata međusobno povezani zadaci. Mnogi modeli za detekciju objekata u svojoj strukturi koriste komponente koje su slične modelima za klasifikaciju slika. Razlika je u tome što detekcijski modeli dodatno uključuju mehanizme koji omogućuju određivanje lokacije objekta na slici.

Razvoj učinkovitih metoda za detekciju objekata omogućio je brojne nove primjene u području računalnog vida. Sustavi koji mogu prepoznati i locirati objekte na slici koriste se u autonomnim vozilima, sustavima video nadzora, medicinskoj analizi slika i mnogim drugim područjima. Upravo zbog toga detekcija objekata predstavlja jedan od najvažnijih zadataka suvremenog računalnog vida.



Slika 2.1 Prikaz razlike između klasifikacije slike i detekcije objekata


2.2 Primjene detekcije objekata

Razvoj metoda za detekciju objekata omogućio je njihovu primjenu u velikom broju različitih područja. Sustavi temeljeni na računalnom vidu danas mogu automatski analizirati slike ili videozapise te prepoznati objekte koji se nalaze unutar scene. Takva tehnologija koristi se u različitim svakodnevnim i industrijskim sustavima jer omogućuje brzu obradu velikih količina vizualnih podataka bez potrebe za stalnom ljudskom intervencijom.

Jedno od područja u kojem se detekcija objekata često koristi jest sigurnost i video nadzor. U sustavima nadzornih kamera algoritmi mogu automatski prepoznati osobe ili vozila te pratiti

njihovo kretanje unutar određenog prostora. Takvi sustavi koriste se, primjerice, u trgovačkim centrima, javnim institucijama ili prometnim sustavima. Automatizirana analiza videozapisa omogućuje lakše praćenje događaja i bržu reakciju u situacijama koje zahtijevaju dodatnu pažnju. Detekcija objekata također ima značajnu primjenu u području trgovine i analize ponašanja kupaca. U modernim trgovinama i supermarketima sustavi računalnog vida mogu analizirati kretanje kupaca unutar prodajnog prostora, prepoznati proizvode na policama ili pratiti stanje zaliha. Na taj način moguće je dobiti informacije o tome koji se proizvodi najčešće uzimaju s polica ili koliko se kupci zadržavaju u određenim dijelovima trgovine. Takve informacije mogu pomoći u boljoj organizaciji prodajnog prostora i optimizaciji poslovanja. U poljoprivredi se metode detekcije objekata koriste za praćenje stanja usjeva i biljaka. Kamere postavljene na dronovima ili drugim uređajima mogu snimati poljoprivredne površine, dok algoritmi računalnog vida analiziraju slike i prepoznaju različite vrste biljaka, korov ili moguće promjene na usjevima. Ovakav pristup omogućuje učinkovitije upravljanje poljoprivrednim površinama i pravovremeno reagiranje na potencijalne probleme. Detekcija objekata koristi se i u području sporta i analize sportskih događaja. Sustavi računalnog vida mogu automatski prepoznati igrače, loptu ili druge elemente igre te pratiti njihovo kretanje tijekom utakmice. Takve analize koriste se za statistiku, analizu taktike ili poboljšanje sportskih performansi.

Osim navedenih primjena, detekcija objekata koristi se i u različitim digitalnim aplikacijama, primjerice u aplikacijama za pretraživanje slika, filtriranje sadržaja ili automatsko označavanje fotografija. Sve veća dostupnost naprednih modela dubokog učenja omogućuje razvoj novih rješenja koja mogu automatski analizirati vizualni sadržaj i izdvojiti relevantne informacije. Zbog svoje fleksibilnosti i široke primjene, detekcija objekata predstavlja jedno od najvažnijih područja suvremenog računalnog vida. Razvoj novih algoritama i modela omogućuje sve točnije i brže prepoznavanje objekata, što dodatno proširuje mogućnosti primjene ove tehnologije u različitim sustavima i aplikacijama.



Slika 2.2 Primjena detekcije objekata u sustavima video nadzora

2.3 Metode za detekciju objekata

Razvoj metoda za detekciju objekata značajno se promijenio tijekom posljednjih desetljeća. U ranim fazama istraživanja računalnog vida detekcija objekata temeljila se na klasičnim metodama obrade slike i ručno definiranim značajkama. Takvi pristupi koristili su različite matematičke tehnike za prepoznavanje oblika, rubova ili tekstura na slici. Iako su takve metode mogle dati određene rezultate, njihova točnost bila je ograničena, posebno u složenijim scenama ili u situacijama kada su se objekti pojavili u različitim veličinama i položajima. Jedan od poznatijih pristupa iz ranijeg razdoblja bio je korištenje metoda koje analiziraju određene vizualne značajke slike, poput rubova ili kontrasta. Algoritmi su pokušavali prepoznati karakteristične obrasce koji bi mogli ukazivati na prisutnost određenog objekta. Međutim, takve metode često su zahtijevale ručno definiranje pravila i parametara, što je otežavalo njihovu primjenu u različitim uvjetima. S razvojem strojnog učenja i povećanjem dostupnosti velikih skupova podataka počeli su se razvijati napredniji pristupi koji koriste neuronske mreže. Duboke neuronske mreže omogućile su modelima da automatski uče relevantne značajke iz podataka bez potrebe za ručnim definiranjem pravila. Ovakav pristup pokazao se znatno učinkovitijim u zadacima računalnog vida, uključujući detekciju objekata.

U suvremenim sustavima detekcije objekata najčešće se koriste modeli temeljeni na konvolucijskim neuronskim mrežama (CNN). Ove mreže posebno su prilagođene obradi slikovnih podataka jer mogu prepoznati prostorne obrasce i strukture unutar slike. Tijekom procesa treniranja model uči prepoznati karakteristične značajke različitih objekata te ih kasnije može identificirati na novim slikama. Današnje metode za detekciju objekata mogu se podijeliti u dvije osnovne skupine: dvostupanjske (two-stage) i jednostupanjske (one-stage) metode. Kod dvostupanjskih metoda proces detekcije odvija se u dva koraka. U prvom koraku model generira potencijalna područja na slici u kojima bi se mogli nalaziti objekti, dok se u drugom koraku ta područja dodatno analiziraju i klasificiraju. Primjeri takvih metoda su modeli iz obitelji R-CNN. S druge strane, jednostupanjske metode pokušavaju istovremeno odrediti lokaciju i klasifikaciju objekta u jednom koraku. Takav pristup omogućuje bržu obradu slike jer se cijeli proces detekcije provodi unutar jedne neuronske mreže. Zbog svoje brzine i učinkovitosti ove metode posebno su pogodne za primjene u stvarnom vremenu. Među najpoznatijim modelima iz ove skupine nalaze se YOLO (You Only Look Once) i SSD (Single Shot Detector). Razvoj ovih metoda značajno je unaprijedio mogućnosti detekcije objekata. Moderni modeli mogu postići visoku razinu točnosti te istovremeno analizirati velik broj objekata na slici. Upravo zbog toga detekcija objekata danas predstavlja jedno od najaktivnijih područja istraživanja u računalnom vidu.

3 YOLO model za detekciju objekata

Razvoj dubokog učenja doveo je do značajnog napretka u području detekcije objekata, a među najpoznatijim pristupima ističe se YOLO model (*You Only Look Once*). Ova metoda razvijena je s ciljem postizanja visoke brzine i dobre točnosti pri prepoznavanju objekata na slikama i videozapisima. Za razliku od ranijih pristupa koji su detekciju provodili u više koraka, YOLO pristup pokušava riješiti cijeli problem detekcije unutar jedne neuronske mreže. Osnovna ideja ovog modela jest da se slika promatra kao jedinstvena cjelina te da neuronska mreža istovremeno predviđa položaj i vrstu objekata koji se nalaze na slici. Na taj način model može brzo analizirati vizualni sadržaj i prepoznati više objekata unutar jedne slike. Upravo zbog toga YOLO modeli posebno su pogodni za primjene u kojima je važna brza obrada podataka, primjerice u sustavima koji rade u stvarnom vremenu. Tijekom godina razvijeno je više verzija YOLO modela, pri čemu je svaka nova verzija donijela određena poboljšanja u pogledu točnosti, brzine i stabilnosti modela. Poboljšanja su uključivala promjene u arhitekturi neuronske mreže, optimizaciju načina treniranja te uvođenje novih tehnika za obradu i interpretaciju slike. Zahvaljujući tim unapređenjima YOLO modeli postali su jedan od najčešće korištenih pristupa za detekciju objekata. U novijim verzijama naglasak je stavljen na pojednostavljenje korištenja modela i lakšu integraciju u različite aplikacije. Moderni YOLO modeli omogućuju relativno jednostavno treniranje na vlastitim skupovima podataka, kao i primjenu na različitim vrstama slika i videozapisa. Zbog toga su postali popularan izbor u istraživačkim projektima, ali i u praktičnim primjenama računalnog vida. U nastavku poglavlja bit će detaljnije objašnjena osnovna ideja YOLO algoritma, razvoj modela kroz različite verzije te glavne karakteristike najnovije verzije modela, YOLOv8, koja je korištena u praktičnom dijelu ovog rada.

3.1 Osnovna ideja YOLO algoritma

YOLO (*You Only Look Once*) predstavlja pristup detekciji objekata koji koristi konvolucijsku neuronsku mrežu za istovremeno prepoznavanje i lociranje objekata na slici. Za razliku od nekih

ranijih metoda koje su analizirale sliku u više koraka, YOLO problem detekcije promatra kao jedinstveni zadatak regresije. To znači da model izravno predviđa koordinate objekata i njihove klase na temelju ulazne slike. U ovom pristupu ulazna slika dijeli se na mrežu manjih ćelija (grid). Svaka ćelija mreže odgovorna je za predviđanje određenog broja mogućih objekata koji se nalaze unutar tog dijela slike. Za svaki potencijalni objekt model predviđa nekoliko važnih informacija: položaj pravokutnog okvira (*bounding box*), dimenzije tog okvira te vjerojatnost pripadnosti određenoj klasi objekta. Na temelju tih predviđanja moguće je odrediti koji se objekti nalaze na slici i gdje su smješteni.

Jedna od važnih karakteristika YOLO algoritma jest korištenje vrijednosti pouzdanosti (*confidence score*). Ova vrijednost pokazuje kolika je vjerojatnost da određeni okvir zaista sadrži objekt. Tijekom procesa detekcije model može predvidjeti veći broj potencijalnih okvira, ali se nakon toga primjenjuju dodatne metode filtriranja kako bi se uklonili manje pouzdani rezultati. Jedna od najčešće korištenih tehnika je *Non-Maximum Suppression (NMS)*, koja omogućuje uklanjanje preklapajućih okvira i zadržavanje onih koji imaju najveću vrijednost pouzdanosti. Važnu ulogu u radu YOLO modela ima i arhitektura konvolucijske neuronske mreže. Ova mreža tijekom treniranja uči prepoznati različite vizualne značajke objekata, poput oblika, rubova ili tekstura. Kako se informacije prenose kroz slojeve mreže, model postupno uči složenije obrasce koji omogućuju razlikovanje različitih objekata unutar slike. Zahvaljujući ovakvom načinu rada YOLO algoritam može vrlo brzo obraditi sliku i detektirati objekte. Upravo zbog toga često se koristi u situacijama gdje je potrebna brza analiza vizualnih podataka. Iako je brzina jedna od njegovih glavnih prednosti, model također može postići dobru razinu točnosti kada je pravilno treniran na odgovarajućem skupu podataka. Za bolje razumijevanje načina rada YOLO algoritma često se koristi vizualni prikaz podjele slike na mrežu ćelija i predviđanja okvira objekata. Takvi prikazi pomažu u razumijevanju načina na koji model analizira sliku i identificira objekte unutar nje.

3.2 Razvoj YOLO modela kroz verzije

Od pojave prvog YOLO modela razvijeno je više njegovih verzija koje su postupno unapređivale način detekcije objekata. Svaka nova verzija nastojala je poboljšati određene nedostatke prethodne, bilo kroz povećanje točnosti, bržu obradu slike ili stabilniji proces treniranja modela. Prva verzija, **YOLOv1**, predstavljena je 2016. godine i donijela je potpuno drugačiji pristup detekciji objekata u odnosu na tadašnje metode. Umjesto da se detekcija provodi u više odvojenih koraka, ovaj model pokušavao je riješiti cijeli zadatak u jednom prolazu kroz neuronsku mrežu. Time je postignuta velika brzina obrade, što je bio jedan od glavnih razloga za popularnost ovog pristupa. Ipak, model je imao i određena ograničenja, posebno kada je riječ o detekciji manjih objekata ili objekata koji se nalaze vrlo blizu jedan drugome. Sljedeća verzija, **YOLOv2**, donijela je nekoliko važnih poboljšanja. Jedna od značajnijih promjena bilo je uvođenje tzv. *anchor boxova*, koji omogućuju preciznije određivanje veličine i položaja objekata na slici. Također su uvedena poboljšanja u procesu treniranja neuronske mreže, što je doprinijelo stabilnijim i točnijim rezultatima. Nakon toga razvijen je **YOLOv3**, koji je dodatno unaprijedio sposobnost modela za prepoznavanje objekata različitih veličina. U ovoj verziji model može detektirati objekte na više razina unutar mreže, što pomaže pri prepoznavanju manjih objekata na slici. Ova verzija postala je vrlo popularna jer je nudila dobar odnos između brzine i točnosti. Kasnije su razvijene verzije **YOLOv4** i **YOLOv5**, koje su dodatno optimizirale arhitekturu modela i način treniranja. U tim verzijama uvedene su različite tehnike koje poboljšavaju performanse modela, primjerice naprednije metode augmentacije podataka i optimizacije neuronske mreže. Time je omogućeno postizanje bolje točnosti detekcije uz zadržavanje relativno velike brzine obrade. U novijem razdoblju razvijene su i modernije verzije modela poput **YOLOv6**, **YOLOv7** i **YOLOv8**, koje donose dodatna poboljšanja u arhitekturi mreže i učinkovitosti modela. Posebno se ističe **YOLOv8**, koji je predstavljen 2023. godine te nudi jednostavniju implementaciju i fleksibilnije mogućnosti treniranja na različitim skupovima podataka. Upravo zbog svoje stabilnosti i jednostavne primjene često se koristi u istraživačkim i edukacijskim projektima. Osim toga, istraživanja u ovom području nastavljaju se i dalje, pa su u novije vrijeme predstavljene i dodatne verzije poput **YOLOv9**, koje uvode nove ideje i arhitekturna poboljšanja.


Unatoč tome, YOLOv8 i dalje predstavlja vrlo popularan izbor za implementaciju modela detekcije objekata, što je razlog zbog kojeg je upravo ta verzija korištena u praktičnom dijelu ovog rada.

3.3 YOLOv8 model i njegove karakteristike

YOLOv8 predstavlja jednu od novijih implementacija YOLO modela koja je razvijena s ciljem poboljšanja performansi i jednostavnije primjene u različitim zadacima računalnog vida. Ovaj model razvila je tvrtka Ultralytics, a njegova popularnost brzo je porasla jer omogućuje relativno jednostavno treniranje modela te implementaciju na vlastitim skupovima podataka. U odnosu na ranije verzije modela, YOLOv8 donosi određene arhitekturne promjene koje omogućuju učinkovitiju obradu slike i preciznije prepoznavanje objekata.

Arhitektura YOLOv8 modela sastoji se od nekoliko glavnih dijelova koji zajedno omogućuju analizu slike i generiranje predviđanja. U osnovi se model može podijeliti na tri glavna dijela: backbone, neck i head. Svaki od tih dijelova ima specifičnu ulogu u procesu obrade slike i detekcije objekata. Prvi dio modela, poznat kao backbone, zadužen je za izdvajanje značajki iz ulazne slike. Tijekom ovog procesa neuronska mreža analizira sliku kroz niz konvolucijskih slojeva i postupno izdvaja vizualne obrasce poput rubova, oblika ili tekstura. U YOLOv8 modelu koristi se unaprijeđena arhitektura temeljena na CSP pristupu, pri čemu se koriste tzv. C2f moduli koji omogućuju učinkovitiji protok informacija kroz mrežu i bolje iskorištavanje značajki slike. Nakon izdvajanja osnovnih značajki slijedi neck dio modela koji ima zadatak povezati različite razine informacija dobivenih iz backbonea. U ovom dijelu model kombinira značajke dobivene iz različitih slojeva mreže kako bi bolje razumio objekte različitih veličina. U YOLOv8 modelu za taj proces koristi se kombinacija struktura poput FPN (Feature Pyramid Network) i PAN (Path Aggregation Network) koje omogućuju povezivanje informacija iz više razina mreže. Na taj način model može učinkovitije prepoznati i manje i veće objekte koji se nalaze na slici. Završni dio modela naziva se head i u njemu se generiraju konačna predviđanja. Na temelju značajki koje dolaze iz prethodnih dijelova mreže model određuje položaj objekata na slici, njihovu pripadnost određenoj klasi te vjerojatnost da se objekt zaista nalazi u tom području slike. U YOLOv8

modelu koristi se tzv. anchor-free pristup, što znači da model ne koristi unaprijed definirane okvire za predviđanje objekata, već izravno procjenjuje njihov položaj i dimenzije. Ovakav pristup pojednostavljuje proces treniranja i smanjuje broj potrebnih parametara modela. Jedna od važnih karakteristika YOLOv8 modela jest i fleksibilnost pri primjeni. Model se može koristiti ne samo za detekciju objekata, već i za druge zadatke računalnog vida poput segmentacije objekata ili klasifikacije slika. Također postoje različite varijante modela (npr. YOLOv8n, YOLOv8s, YOLOv8m, YOLOv8l i YOLOv8x) koje se razlikuju po veličini mreže i broju parametara. Manji modeli omogućuju bržu obradu i manju potrošnju resursa, dok veći modeli obično postižu veću točnost detekcije. Važna prednost YOLOv8 modela je i relativno jednostavan proces treniranja i implementacije. Zahvaljujući dostupnim bibliotekama i alatima moguće je relativno brzo pripremiti skup podataka, trenirati model te analizirati rezultate detekcije. Zbog toga se YOLOv8 često koristi u istraživačkim radovima, studentskim projektima i različitim eksperimentalnim sustavima računalnog vida. U praktičnom dijelu ovog rada korišten je upravo YOLOv8 model za treniranje sustava detekcije objekata na skupu podataka PASCAL VOC. Model je treniran na označenim slikama, nakon čega su analizirani dobiveni rezultati i performanse modela pomoću različitih evaluacijskih metrika.



Slika 3.1 Arhitektura YOLOv8 modela s glavnim dijelovima: backbone (izdvajanje značajki), neck (spajanje informacija) i head (predviđanje objekata)

4 Skup podataka PASCAL VOC i priprema podataka

Za treniranje modela detekcije objekata u ovom radu korišten je skup podataka **PASCAL VOC 2012**, koji je jedan od najpoznatijih skupova podataka u području računalnog vida. Ovaj skup podataka često se koristi u istraživanjima i razvoju modela za detekciju objekata jer sadrži velik broj slika iz stvarnog okruženja na kojima se nalaze različite kategorije objekata. Kako bi se model mogao uspješno trenirati, potrebno je prethodno pripremiti podatke u odgovarajućem formatu. Proces pripreme podataka uključuje organizaciju slika i anotacija, njihovu konverziju u format koji koristi YOLO model te podjelu podataka na skup za treniranje i skup za validaciju. U sljedećim potpoglavljima bit će detaljnije opisan korišteni skup podataka, način na koji su objekti označeni te postupak pripreme podataka prije samog treniranja modela.

4.1 Opis skupa podataka

Skup podataka PASCAL VOC 2012 (PASCAL Visual Object Classes) jedan je od najpoznatijih i najčešće korištenih skupova podataka u području računalnog vida. Razvijen je u okviru PASCAL VOC izazova s ciljem evaluacije algoritama za zadatke poput klasifikacije slika, detekcije objekata i segmentacije. Zbog svoje široke primjene i kvalitetno označenih podataka često se koristi kao referentni skup podataka pri razvoju i testiranju modela za detekciju objekata. Dataset sadrži više od 11 000 slika iz stvarnog okruženja na kojima su označeni različiti objekti. Na tim slikama nalazi se ukupno više od 27 000 označenih instanci objekata, što omogućuje učinkovito treniranje i evaluaciju modela strojnog učenja. Objekti u datasetu podijeljeni su u 20 različitih klasa, među kojima su aeroplane, bicycle, bird, boat, bottle, bus, car, cat, chair, cow, diningtable, dog, horse, motorbike, person, pottedplant, sheep, sofa, train i tvmonitor. Ove kategorije obuhvaćaju različite vrste objekata poput vozila, životinja i svakodnevnih predmeta, zbog čega je dataset pogodan za razvoj modela koji trebaju prepoznavati objekte u raznovrsnim scenama. Važna karakteristika ovog skupa podataka je i način na koji su objekti označeni. Svaka slika ima pripadajuću anotacijsku datoteku u kojoj su zapisane informacije o objektima koji se nalaze na slici, uključujući naziv klase i koordinate pravokutnog okvira (bounding box) koji označava

položaj objekta. Takve informacije omogućuju modelima za detekciju objekata da nauče ne samo prepoznati objekt, nego i odrediti njegovu točnu lokaciju unutar slike. U ovom radu korišten je PASCAL VOC 2012 dataset preuzet s platforme Kaggle, a za potrebe treniranja modela korišten je dio dostupnih slika koje su zatim podijeljene na skup za treniranje i skup za validaciju.

4.2 Anotacije i struktura podataka

Skup podataka PASCAL VOC 2012 organiziran je u nekoliko osnovnih mapa koje sadrže slike, anotacije i informacije o podjeli podataka. Takva struktura omogućuje jednostavnije korištenje skupa podataka prilikom treniranja i evaluacije modela za detekciju objekata. Jedna od glavnih mapa je JPEGImages, koja sadrži sve slike u .jpg formatu. Svaka slika prikazuje stvarne scene iz svakodnevnog okruženja, a na njima se mogu nalaziti jedan ili više objekata različitih klasa. Slike se koriste kao ulazni podaci za treniranje modela. Druga važna mapa je Annotations, u kojoj se nalaze anotacijske datoteke u XML formatu. Za svaku sliku postoji odgovarajuća XML datoteka koja sadrži informacije o objektima koji se nalaze na slici. U tim datotekama zapisani su naziv klase objekta te koordinate pravokutnog okvira (bounding box) koji označava položaj objekta na slici. Bounding box definiran je pomoću koordinata xmin, ymin, xmax i ymax, koje određuju granice objekta unutar slike.

Osim toga, dataset sadrži i mapu ImageSets, koja definira podjelu podataka na različite skupove. Unutar nje nalaze se tekstualne datoteke koje određuju koje slike pripadaju skupu za treniranje, validaciju ili testiranje. Ova podjela važna je jer omogućuje treniranje modela na jednom dijelu podataka, dok se njegova uspješnost provjerava na slikama koje model prethodno nije vidio. Budući da YOLO modeli koriste drugačiji format anotacija, XML datoteke iz PASCAL VOC skupa podataka potrebno je pretvoriti u YOLO format. U tom formatu svaka slika ima pripadajuću .txt datoteku u kojoj se nalaze informacije o klasi objekta i normaliziranim koordinatama bounding boxa. Takva struktura omogućuje jednostavno učitavanje podataka tijekom treniranja modela u okviru YOLO arhitekture.

4.3 Priprema podataka za treniranje modela

Kako bi se skup podataka mogao koristiti za treniranje YOLOv8 modela, bilo je potrebno provesti nekoliko koraka pripreme podataka. Budući da su anotacije u PASCAL VOC skupu podataka zapisane u XML formatu, najprije je bilo potrebno izdvojiti relevantne informacije o objektima i prilagoditi ih formatu koji koristi YOLO. Proces je proveden u okruženju Google Colab, pri čemu su podaci učitani s Google Drivea. Nakon raspakiravanja skupa podataka definirane su putanje do mapa koje sadrže slike i anotacije. Time je omogućeno dohvaćanje odgovarajućih datoteka potrebnih za daljnju obradu.

U sljedećem koraku iz XML datoteka izdvajale su se informacije o dimenzijama slike te koordinatama bounding boxa za svaki označeni objekt. Te vrijednosti zatim su preračunate u oblik koji koristi YOLO, odnosno zapisane su koordinate središta objekta te njegova širina i visina u odnosu na ukupnu veličinu slike. Dobiveni podaci pohranjeni su u tekstualne datoteke koje predstavljaju oznake objekata za svaku pojedinu sliku. Nakon toga slike i pripadajuće oznake organizirane su u strukturu direktorija koja je potrebna za treniranje modela. Posebno su izdvojene mape za slike i oznake, a podaci su podijeljeni na skup za treniranje i skup za validaciju. Za potrebe ovog rada odabrano je 1500 slika za treniranje modela te 300 slika za validaciju, pri čemu je podjela napravljena nasumičnim odabirom slika iz dostupnog skupa podataka. Na kraju je izrađena konfiguracijska datoteka u YAML formatu koja definira putanju do pripremljenog skupa podataka, kao i raspored mapa koje sadrže slike i pripadajuće oznake. Ova datoteka koristi se prilikom pokretanja treniranja modela kako bi sustav mogao ispravno učitati podatke. Nakon završetka svih navedenih koraka, pripremljeni skup podataka bio je spreman za treniranje YOLOv8 modela i daljnju analizu rezultata.

5 Implementacija YOLOv8 modela

Nakon pripreme skupa podataka pristupilo se implementaciji modela za detekciju objekata. U ovom radu korišten je YOLOv8 model, treniran na prethodno pripremljenom dijelu PASCAL VOC skupa podataka. Cijeli postupak proveden je u okruženju Google Colab, uz korištenje grafičke kartice (GPU) radi ubrzanja procesa treniranja. Implementacija je obuhvatila učitavanje modela, pokretanje treniranja nad definiranim skupom podataka te naknadnu evaluaciju dobivenih rezultata. Tijekom izvođenja korištena je grafička kartica tipa NVIDIA Tesla T4, što je omogućilo značajno brže izvođenje u odnosu na rad na procesoru (CPU). Tijekom rada korištene su odgovarajuće konfiguracijske datoteke i unaprijed definirane klase objekata, čime je osigurana ispravna priprema podataka i uspješno treniranje modela. U nastavku poglavlja detaljnije su opisani koraci postavljanja radnog okruženja, treniranja modela te evaluacije dobivenih rezultata.

5.1 Postavljanje radnog okruženja

Radno okruženje za provedbu eksperimenta postavljeno je u alatu Google Colab, koji omogućuje izvođenje Python koda uz podršku za grafičke kartice (GPU). Na samom početku rada uspostavljena je veza s Google Driveom kako bi se omogućio pristup skupu podataka, ali i spremanje rezultata treniranja modela. Nakon toga instalirana je biblioteka Ultralytics, koja omogućuje jednostavnu implementaciju i rad s YOLOv8 modelima. Skup podataka PASCAL VOC učitani su i raspakirani unutar radnog okruženja. Budući da YOLO zahtijeva drugačiji format anotacija u odnosu na izvorni VOC format, bilo je potrebno izvršiti pretvorbu XML anotacija u YOLO format. Također su definirane sve klase objekata te je izvršena podjela podataka na skup za treniranje i skup za validaciju. U svrhu pravilnog rada modela izrađena je i konfiguracijska YAML datoteka koja opisuje strukturu podataka te pripadajuće klase. Za treniranje modela korišten je unaprijed trenirani YOLOv8 model, čime se primjenjuje pristup prijenosa znanja (transfer learning), što značajno ubrzava proces učenja i poboljšava konačne rezultate. Nakon provedbe svih navedenih koraka, radno okruženje bilo je spremno za treniranje i kasniju evaluaciju modela.

5.2 Treniranje modela

Nakon pripreme podataka pristupilo se treniranju modela. Za treniranje je korišten YOLOv8n model koji je inicijalno učitao s unaprijed treniranim težinama, a zatim dodatno treniran na vlastitom skupu podataka. Prije treniranja korišten je već pripremljen skup podataka u YOLO formatu. Skup podataka podijeljen je na dio za treniranje i dio za validaciju, pri čemu je za treniranje korišteno 1500 slika, a za validaciju 300 slika. Iako su u skupu definirane sve klase objekata, treniranje modela bilo je usmjereno prvenstveno na detekciju klase *person*, koja je i najzastupljenija u korištenom podskupu podataka. Model je treniran kroz 20 epoha uz veličinu slike od 640 piksela i batch veličinu 16. Tijekom treniranja pratili su se osnovni pokazatelji poput gubitka (loss), preciznosti (precision) i odziva (recall), koji su pokazivali postupno poboljšanje modela. Nakon završetka treniranja, spremljen je najbolji model (best.pt), koji je zatim korišten za testiranje na novim slikama. Rezultati detekcije prikazani su pomoću bounding boxova, pri čemu je model uspješno prepoznao objekte klase *person*.

5.3 Evaluacija modela

Nakon treniranja modela provedena je evaluacija na validacijskom skupu podataka korištenjem funkcije `model.val()`. Time su dobivene ključne metrike poput preciznosti (precision), odziva (recall) i mAP vrijednosti, koje opisuju uspješnost modela u detekciji objekata. Uz numeričke rezultate generirane su i dodatne vizualizacije, uključujući matricu zabune te primjere detekcije objekata na slikama. Ovi prikazi omogućuju bolji uvid u način rada modela i njegovu pouzdanost u različitim situacijama. Dobiveni rezultati korišteni su za daljnju analizu performansi modela, a njihova detaljna interpretacija i usporedba s drugim modelima prikazana je u sljedećem poglavlju.

6 Analiza rezultata i usporedba modela


U ovom poglavlju prikazana je detaljnija analiza rezultata dobivenih treniranjem i evaluacijom modela. Kroz različite metrike i vizualne prikaze nastoji se dobiti jasnija slika o tome koliko je model uspješan u detekciji objekata te u kojim situacijama dolazi do pogrešaka. Poseban naglasak stavljen je na interpretaciju osnovnih mjera uspješnosti, kao što su preciznost, odziv i F1-score, jer one daju uvid u to koliko model točno prepoznaje objekte i koliko ih uspješno pronalazi na slikama. Također, analizirana je matrica zabune koja omogućuje pregled točnih i netočnih klasifikacija. Osim numeričkih rezultata, prikazani su i vizualni primjeri detekcije objekata kako bi se lakše uočile stvarne performanse modela na konkretnim slikama. Na kraju je napravljena i usporedba s drugim modelom za detekciju objekata, čime se dobiva bolji uvid u prednosti i nedostatke korištenog pristupa.

6.1 Precision, recall i F1-score

Za procjenu uspješnosti modela korištene su osnovne metrike: preciznost (precision), odziv (recall) i F1-score. Ove metrike omogućuju detaljniji uvid u kvalitetu detekcije objekata, odnosno koliko model točno i potpuno prepoznaje objekte na slikama. Preciznost označava omjer točno detektiranih objekata u odnosu na sve detekcije koje je model napravio.

U ovom radu dobivena vrijednost preciznosti iznosi približno 0.79, što znači da je većina detektiranih objekata zaista pripadala klasi *person*. Drugim riječima, model rijetko daje pogrešne detekcije. Odziv (recall) pokazuje koliko stvarnih objekata model uspije pronaći na slici. Dobivena vrijednost od oko 0.82 ukazuje na to da model uspješno detektira većinu osoba prisutnih na slikama, uz relativno mali broj propuštenih objekata. Za cjelokupnu procjenu koristi se F1-score, koji predstavlja harmonijsku sredinu preciznosti i odziva. Na temelju dobivenih vrijednosti izračunat je F1-score koji iznosi približno 0.80, što ukazuje na dobru ravnotežu između točnosti i potpunosti detekcije. Osim navedenih metrika, važan pokazatelj uspješnosti modela je i mAP (mean Average Precision).

U ovom radu $mAP@0.5$ iznosi oko 0.87, što pokazuje da model vrlo dobro prepoznaje objekte pri standardnom kriteriju preklapanja. Stroži kriterij $mAP@0.5:0.95$ iznosi oko 0.65, što je očekivano niža vrijednost, ali i dalje potvrđuje stabilnost modela u različitim uvjetima. Na temelju svih dobivenih rezultata može se zaključiti da model postiže vrlo dobre performanse u detekciji objekata klase *person*. Na prikazanim grafovima može se vidjeti kretanje metrika i funkcija gubitka tijekom treniranja modela. Vrijednosti loss funkcija postupno se smanjuju, dok preciznost, odziv i mAP vrijednosti rastu i stabiliziraju se, što ukazuje na uspješno učenje modela i njegovu sposobnost generalizacije na nove podatke.




Slika 6.1 Grafovi treniranja YOLOv8 modela


6.2 Matrica zabune (Confusion Matrix)

Matrica zabune korištena je kao dodatni alat za analizu performansi modela jer omogućuje detaljniji uvid u način na koji model donosi odluke. Pomoću nje može se jasno vidjeti koliko je puta model ispravno detektirao objekte, ali i u kojim situacijama dolazi do pogrešaka.

U ovom radu model je treniran primarno za detekciju jedne klase (person), zbog čega je i sama matrica pojednostavljena u odnosu na klasične višeklasne probleme. **Na** prvoj slici prikazana je matrica zabune za trenirani model, gdje se može uočiti da se najveći broj vrijednosti odnosi upravo na tu klasu. Time je jasno vidljiv odnos između točnih detekcija i propuštenih objekata. Iz prikazane matrice vidljivo je da model u većini slučajeva uspješno prepoznaje osobe na slikama. Najveći broj vrijednosti nalazi se na dijagonali matrice, što ukazuje na točne predikcije. Manji broj pogrešaka javlja se u slučajevima kada model ne uspije detektirati osobu (false negative) ili kada detektira objekt tamo gdje ga zapravo nema (false positive). Pogreške se najčešće pojavljuju u zahtjevnijim uvjetima, primjerice kada su osobe djelomično zaklonjene, udaljene ili se nalaze u lošijim uvjetima osvjetljenja. Također, složenija pozadina može otežati modelu razlikovanje objekta od okoline. Budući da se radi o jednoj klasi, u ovom slučaju ne dolazi do zamjene između različitih kategorija objekata, već se pogreške odnose isključivo na propuštene ili dodatne detekcije unutar iste klase. Zbog toga je interpretacija matrice jednostavnija, ali i dalje vrlo korisna za razumijevanje ponašanja modela. Kako bi se dobio širi kontekst, dodatno je prikazana matrica zabune za unaprijed trenirani YOLOv8 model na COCO skupu podataka. **Na** drugoj slici prikazana je normalizirana matrica zabune za COCO model, gdje se može vidjeti znatno veći broj klasa i složenija struktura matrice. Za razliku od prethodnog slučaja, ovdje model radi s velikim brojem različitih klasa, zbog čega je matrica znatno složenija. Može se primijetiti da do pogrešaka najčešće dolazi između vizualno sličnih objekata, što je tipično za višeklasne probleme. Usporedbom ove dvije matrice može se zaključiti da model postiže vrlo dobre rezultate u jednostavnijem scenariju s jednom klasom, dok se u složenijim uvjetima povećava broj pogrešaka. Unatoč tome, model i dalje pokazuje dobru sposobnost razlikovanja objekata.




Slika 6.2 Matrica zabune za YOLOv8 model treniran na VOC skupu (klasa person)



Slika 6.2 Normalizirana matrica zabune za YOLOv8 model na COCO skupu

6.3 Vizualizacija detekcije objekata

Kako bi se dobio bolji uvid u stvarno ponašanje modela, provedena je vizualizacija detekcije objekata na odabranim testnim slikama. Za tu svrhu izdvojeno je nekoliko slika iz skupa podataka te su korištene kao primjer za provjeru uspješnosti modela u realnim uvjetima. Na slikama su prikazani detektirani objekti pomoću pravokutnih okvira (bounding box), uz pripadajuće vrijednosti pouzdanosti (confidence score). Ove vrijednosti pokazuju koliko je model siguran u svoju detekciju, pri čemu veće vrijednosti označavaju veću pouzdanost. Dobiveni rezultati pokazuju da model u većini slučajeva uspješno prepoznaje osobe na slici te ih pravilno označava. Bounding boxovi su uglavnom dobro pozicionirani i prate oblik objekta, što ukazuje na dobru naučenost modela. U pojedinim situacijama uočene su i manje pogreške, primjerice kada su osobe djelomično zaklonjene ili kada su uvjeti na slici lošiji, poput slabijeg osvjetljenja. U takvim slučajevima model može propustiti detekciju ili prikazati manju vrijednost pouzdanosti. Na četvrtoj slici 6.3. može se uočiti primjer djelomične pogreške modela, gdje nisu detektirane sve osobe prisutne na slici. Takve situacije najčešće se javljaju zbog nepovoljnih uvjeta poput slabijeg osvjetljenja, većih udaljenosti ili preklapanja objekata, što može otežati modelu jasno prepoznavanje svih elemenata u sceni. Ovakvi primjeri ukazuju na ograničenja modela, ali su ujedno očekivani u praktičnim primjenama računalnog vida. Također, ovakvi rezultati naglašavaju važnost kvalitetnih i raznolikih podataka tijekom treniranja modela, jer veća raznolikost podataka može doprinijeti boljoj generalizaciji modela u složenijim uvjetima. Unatoč tome, vizualni rezultati potvrđuju da model pouzdano detektira objekte klase person te se može uspješno primijeniti na nove, prethodno neviđene slike.



Slika 6.3 primjer detekcije objekata pomoću treniranog YOLOv8 modela



Slika 6.3 drugi primjer detekcije objekata pomoću treniranog YOLOv8 modela



Slika 6.3 treći primjer detekcije objekata pomoću treniranog YOLOv8 modela



Slika 6.3 Primjer djelomične detekcije (model nije prepoznao sve osobe)




Slika 6.3 peti primjer detekcije objekata pomoću treniranog YOLOv8 modela

6.4 Usporedba s SSD modelom

Kako bi se dodatno procijenila uspješnost treniranog modela, provedena je usporedba s jednostavnijim modelom za detekciju objekata, odnosno SSD (Single Shot Detector) modelom. U ovom radu YOLOv8 model treniran je na prilagođenom dijelu PASCAL VOC skupa podataka, pri čemu je fokus bio na detekciji jedne klase – *person*. Usporedba je napravljena na istoj testnoj

slici kako bi rezultati bili što realniji i usporedivi. Na toj slici YOLOv8 model uspješno detektira osobe, ali prepoznaje dvije od ukupno tri prisutne osobe. S druge strane, SSD model na istoj slici detektira sve tri osobe. Ova razlika u rezultatima može se objasniti načinom treniranja modela. YOLOv8 model u ovom radu treniran je na relativno manjem broju slika i usmjeren samo na jednu klasu, zbog čega ima ograničenu raznolikost primjera tijekom učenja. U zahtjevnijim uvjetima, poput slabijeg osvjetljenja ili složenije pozadine, to može dovesti do propuštanja pojedinih objekata. SSD model, iako jednostavniji po svojoj strukturi, treniran je na znatno većem i raznovrsnijem skupu podataka (npr. COCO), što mu omogućuje bolju generalizaciju u različitim situacijama. Upravo zbog toga u ovom primjeru uspijeva detektirati sve osobe na slici. Unatoč tome, dobro je naglasiti da YOLOv8 model postiže vrlo dobre rezultate s obzirom na ograničen skup podataka i broj epoha treniranja. Njegova glavna prednost je brzina izvođenja i mogućnost prilagodbe specifičnim zadacima, što ga čini vrlo pogodnim za praktične primjene. Na temelju ove usporedbe može se zaključiti da unaprijed trenirani modeli mogu imati prednost u općenitim zadacima, dok modeli trenirani na prilagođenim podacima, poput korištenog YOLOv8 modela, mogu dati vrlo dobre rezultate kada su usmjereni na konkretan problem.

SSD - detekcija osoba



Slika 6.4 rezultat detekcije pomoću SSD modela



Slika 6.4 rezultat djelomične detekcije pomoću YOLOv8 modela

7 Zaključak

U ovom radu prikazan je postupak primjene YOLOv8 modela za detekciju objekata na slikama, pri čemu je model treniran za prepoznavanje jedne klase, odnosno *person*. Kroz sve faze rada, od pripreme skupa podataka i njegove prilagodbe, pa sve do treniranja i evaluacije, može se uočiti koliko je važna kvalitetna priprema podataka za postizanje dobrih rezultata. Dobiveni rezultati pokazali su da model postiže vrlo dobru razinu uspješnosti u detekciji osoba. Vrijednosti preciznosti i odziva ukazuju na to da u većini slučajeva ispravno prepoznaje objekte, uz relativno mali broj pogrešaka. mAP metrike dodatno potvrđuju stabilnost, iako su u određenim situacijama uočena manja odstupanja, poput propuštanja objekata u složenijim uvjetima. Takvi rezultati su očekivani s obzirom na ograničen skup podataka i fokus na jednu klasu. Vizualna analiza rezultata dodatno je potvrdila da model uspješno detektira osobe na većini testnih slika te pravilno određuje njihov položaj pomoću bounding boxova. Uočene pogreške najčešće su se javljale u situacijama s lošijim osvjetljenjem, većom udaljenošću objekata ili njihovim preklapanjem, što su ujedno i tipični izazovi u zadacima detekcije objekata. U svrhu dodatne analize provedena je i usporedba s jednostavnijim modelom za detekciju objekata, odnosno SSD modelom. Rezultati su pokazali da SSD model u pojedinim slučajevima uspije detektirati veći broj objekata, što se može objasniti treniranjem na većem i raznovrsnijem skupu podataka. S druge strane, YOLOv8 model korišten u ovom radu pokazao je vrlo dobre rezultate s obzirom na ograničene uvjete treniranja i specifičan zadatak. Na temelju svega može se zaključiti da modeli trenirani za specifične zadatke mogu postići visoku razinu točnosti, ali uz određena ograničenja u složenijim scenarijima. YOLOv8 se pokazao kao učinkovit, brz i praktičan pristup detekciji objekata, s jasnim potencijalom za daljnje unapređenje kroz povećanje količine podataka i dodatno treniranje.

8 Literatura

<https://www.geeksforgeeks.org/computer-vision/what-is-object-detection-in-computer-vision/>

https://en.wikipedia.org/wiki/Object_detection

https://www.d2l.ai/chapter_computer-vision/index.html

<https://www.ibm.com/think/topics/computer-vision>

<https://hr.macgence.com/blog/yolo-object-detection-revolutionising-computer-vision-indefinitely/>

<https://kili-technology.com/blog/yolo-algorithm-real-time-object-detection-from-a-to-z>

<https://zeeshan.p2pclouds.net/blogs/what-is-yolo-models-and-how-it-is-used-in-object-detection/>

<https://www.geeksforgeeks.org/computer-vision/how-does-yolo-work-for-object-detection/>

Jiang, X., Hadid, A., Pang, Y., Granger, E., Feng, X., *Deep Learning in Object Detection and Recognition*, dostupno online

9 Popis slika

Slika 2.1 Prikaz razlike između klasifikacije slike i detekcije objekata.....	5
Slika 2.2 Primjena detekcije objekata u sustavima video nadzora.....	7
Slika 3.1 Arhitektura YOLOv8 modela s glavnim dijelovima: backbone (izdvajanje značajki), neck (spajanje informacija) i head (predviđanje objekata)	13
Slika 6.1 Grafovi treniranja YOLOv8 modela	20
Slika 6.2 Matrica zabune za YOLOv8 model treniran na VOC skupu (klasa person).....	22
Slika 6.3 primjer detekcije objekata pomoću treniranog YOLOv8 modela.....	24
Slika 6.3 drugi primjer detekcije objekata pomoću treniranog YOLOv8 modela	24
Slika 6.3 treći primjer detekcije objekata pomoću treniranog YOLOv8 modela.....	24
Slika 6.3 primjer djelomične detekcije (model nije prepoznao sve osobe).....	25
Slika 6.3 peti primjer detekcije objekata pomoću treniranog YOLOv8 modela	25
Slika 6.4 rezultat detekcije pomoću SSD modela	26
Slika 6.4 rezultat djelomične detekcije pomoću YOLOv8 modela	27